

Analítica de Ventas en Databricks: Del Dataset Superstore al Modelo Predictivo

Victor Sánchez, Arquímedes Morán, Greisy Coronado, Juan Morales, Alejandro Gonzalez

Correos de los autores: victor.sanchez8@utp.ac.pa, arquimedes.moran@utp.ac.pa, juan.morales13@utp.ac.pa, greisy.coronado@utp.ac.pa, alejandro.gonzalez11@utp.ac.pa

Resumen – Este proyecto aplica el ciclo completo de analítica de datos sobre el dataset Superstore Sales utilizando Databricks Free Edition. Se realizó la limpieza y estandarización de los datos, un análisis exploratorio con indicadores clave, cinco visualizaciones y filtros interactivos por Región y Categoría, seis consultas SQL avanzadas con funciones de ventana y expresiones condicionales, y un modelo de regresión Gradient Boosted Trees para predecir el monto de venta. Los resultados evidencian la alta participación de la región West en las ventas y una relación entre descuentos agresivos y menor rentabilidad.

DESCRIPCION INTRODUCCION Y JUSTIFICACION

Las empresas minoristas generan grandes volúmenes de datos transaccionales que, sin un proceso adecuado de limpieza y análisis, no aportan valor a la toma de decisiones. Este proyecto surge de la necesidad de aplicar un flujo de trabajo de analítica de datos de extremo a extremo, desde la ingesta hasta un modelo predictivo, sobre un conjunto de datos real de ventas minoristas (Superstore Sales), con el fin de identificar patrones de ventas, rentabilidad y comportamiento de descuentos que sirvan de base para decisiones comerciales y operativas.

DESCRIPCION DEL PROYECTO

La solución se implementó íntegramente en Databricks Free Edition, dividiendo el trabajo en notebooks especializados: limpieza de datos, análisis exploratorio con dashboard interactivo, consultas SQL avanzadas y un modelo de analítica avanzada. Se optó por esta plataforma por su integración nativa entre SQL, PySpark y visualización de dashboards, lo que permite un flujo de trabajo colaborativo y reproducible sin necesidad de infraestructura adicional.

DESCRIPCION DE ALTO NIVEL DE LA SOLUCION

El proyecto utiliza PySpark (`pyspark.sql.functions`) para la limpieza y agregación de datos, Spark SQL para las consultas analíticas con funciones de ventana (`DENSE_RANK`, `RANK`, `LAG`) y expresiones `CASE WHEN`, y PySpark MLlib (`StringIndexer`, `OneHotEncoder`, `VectorAssembler`, `GBTRRegressor`, `RegressionEvaluator`) para la construcción y evaluación del modelo predictivo. En la Fig. 1 se muestra el dashboard interactivo Superstore_Analytics con sus filtros e indicadores clave.

ESQUEMATICOS DE LA PROPUESTA (OPCIONAL)

El flujo de trabajo se estructuró en notebooks secuenciales (limpieza, análisis exploratorio, SQL y analítica avanzada), cada uno construido sobre la tabla Delta `superstore_limpio`. En la Fig. 2 se muestra la distribución de ventas por región y en la Fig. 3 el top 10 de productos con mayor ganancia, ambos generados a partir del notebook de análisis exploratorio.

DESCRIPCION DEL PROYECTO

Las seis consultas SQL avanzadas permitieron identificar a los clientes de mayor valor, clasificar pedidos por rentabilidad, analizar la evolución mensual de ventas (Fig. 7) y detectar sub-categorías con descuentos agresivos y baja rentabilidad. Adicionalmente, se entrenó un modelo Gradient Boosted Trees (GBTRRegressor) para predecir el monto de venta a partir de la cantidad, el descuento y variables categóricas del pedido, excluyendo la variable Profit para evitar fuga de información. La Fig. 8 muestra la importancia relativa de cada variable en el modelo entrenado.

CONCLUSIONES

El desarrollo de este proyecto permitió aplicar de forma integral el ciclo de analítica de datos sobre un conjunto de ventas minoristas. La limpieza garantizó la integridad de la información, el análisis exploratorio y el dashboard interactivo evidenciaron la alta participación de la región West en las ventas, y las consultas SQL revelaron que los descuentos superiores al 20% en sub-categorías como Tables y Bookcases afectan negativamente la rentabilidad. El modelo predictivo mostró un ajuste moderado, lo que sugiere que existen factores adicionales no capturados en las variables disponibles. Como trabajo futuro queda pendiente probar otros algoritmos de regresión y ampliar el modelo con variables temporales.

REFERENCIAS

- [1] Leonism, "sample-superstore/data/superstore.csv," GitHub. [Online]. Available: <https://github.com/leonism/sample-superstore/blob/master/data/superstore.csv>

Sitios Web Consultados

- [2] Apache Spark, "Window Functions – Spark SQL Guide." [Online]. Available: <https://spark.apache.org/docs/latest/sql-ref-syntax-qry-select-window.html>
- [3] Apache Spark, "MLlib: Regression – GBTRRegressor." [Online]. Available: <https://spark.apache.org/docs/latest/ml-classification-regression.html#gradient-boosted-tree-regression>
- [4] Hazlo con Datos, "Crea tu Primer Dashboard en Databricks Paso a Paso," Aug. 13, 2025. [Video]. Available: <https://www.youtube.com/watch?v=aV6maxkGtCw> [Accessed: Jul. 1, 2026].



Figura 1. Dashboard interactivo Superstore_Analytics con filtros de Región y Categoría




Figura 2. Distribución de ventas por región




Figura 3. Top 10 productos con mayor ganancia



Figura 4. Rendimiento por Categoría



Figura 5. Distribución de Ventas y Ganancia



Figura 6. Relación entre Descuento y Ganancia




Figura 7. Evolución mensual de ventas con variación respecto al mes anterior (consulta SQL con LAG)




Figura 8. Importancia de variables del modelo predictivo (GBRegressor)